

# Introducción a las Redes Neuronales Convolucionales (CNN)

---

Las Redes Neuronales Convolucionales (CNN) son un tipo de red neuronal especialmente eficaz para tareas de visión por computadora. A diferencia de las redes neuronales densamente conectadas, las CNN utilizan capas convolucionales para detectar patrones locales en las imágenes, lo que las hace más eficientes y precisas para estas tareas.

## Componentes de una CNN

### Capas Convolucionales

Las capas convolucionales aplican filtros (kernels) que recorren la imagen de entrada, produciendo mapas de características que detectan patrones locales. Cada filtro es capaz de capturar diferentes aspectos de la imagen, como bordes, texturas y formas.

### Fundamentos de las Capas Convolucionales

Las capas convolucionales son fundamentales en las Redes Neuronales Convolucionales (CNN) y se utilizan para extraer características de las imágenes. Estas capas aplican filtros (kernels) sobre la imagen de entrada para detectar patrones locales, como bordes y texturas.

### Operación de Convolución

#### 1. Kernel y Multiplicación Elemento a Elemento:

- Un kernel es una pequeña matriz de pesos que se desliza sobre la imagen de entrada.
- En cada posición, el kernel realiza una multiplicación elemento a elemento con la porción correspondiente de la imagen de entrada.

#### 2. Suma de Resultados:

- Los resultados de las multiplicaciones se suman para producir un único valor en la salida.
- Este valor se convierte en un píxel de la matriz de características de salida.

#### 3. Repetición del Proceso:

- El kernel repite este proceso en todas las posiciones posibles de la imagen de entrada, generando una nueva matriz de características

3 <sub>0</sub>	3 <sub>1</sub>	2 <sub>2</sub>	1	0
0 <sub>2</sub>	0 <sub>2</sub>	1 <sub>0</sub>	3	1
3 <sub>0</sub>	1 <sub>1</sub>	2 <sub>2</sub>	2	3
2	0	0	2	2
2	0	0	0	1

12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

En este ejemplo, el kernel detecta cambios horizontales en la imagen.

Guía interactiva sobre kernels [aquí \(https://setosa.io/ev/image-kernels/\)](https://setosa.io/ev/image-kernels/).

### Comparación con Capas Completamente Conectadas

- **Capas Completamente Conectadas:**
  - Cada neurona está conectada a todas las neuronas de la capa anterior.
  - Utiliza una gran cantidad de parámetros.
- **Capas Convolucionales:**
  - Cada neurona está conectada solo a una pequeña región de la capa anterior.
  - Utiliza menos parámetros, lo que las hace más eficientes y efectivas para detectar características locales.

### Ventajas de las Capas Convolucionales

- **Reducción de Parámetros:**
  - Menos parámetros que una capa completamente conectada, lo que reduce el riesgo de sobreajuste.
- **Detección de Características Locales:**


- Capturan características locales de manera más efectiva, como bordes y texturas.
- **Invariancia a Traslaciones:**
  - Pueden detectar características independientemente de su posición en la imagen.

### Técnicas Comunes en Capas Convolucionales

#### 1. Padding:

El **padding** se utiliza para mantener el tamaño de la salida igual al tamaño de la entrada. Esto se logra agregando píxeles adicionales alrededor de la imagen de entrada. El padding más común es el **zero padding**, donde los píxeles agregados tienen un valor de 0.


- **Ventaja:** Preserva la información en los bordes de la imagen.
- **Objetivo:** Evitar la reducción del tamaño de la imagen después de la convolución.



## 2. Striding:

El **striding** controla el paso con el que el kernel se mueve sobre la imagen de entrada.

- Stride de 1: El kernel se mueve un píxel a la vez (convención estándar).
- Stride de 2: El kernel se mueve dos píxeles a la vez, reduciendo el tamaño de la salida.
- **Ventaja:** Reduce las dimensiones espaciales de la salida, disminuyendo el número de parámetros.
- **Objetivo:** Controlar el tamaño de la salida y permitir la reducción dimensional de la imagen.



Estas técnicas son esenciales para controlar el tamaño de las salidas y mejorar la eficiencia de las CNN.

## Resumen

Las capas convolucionales son componentes esenciales de las CNN, permitiendo la detección eficiente de características locales en las imágenes con menos parámetros que las capas completamente conectadas. Técnicas como padding y striding son fundamentales para ajustar el tamaño de las salidas y mejorar la eficiencia del modelo.

Type *Markdown* and LaTeX:  $\alpha^2$

In [ ]: